

Basket-AR: Riconoscimento Automatico di Azioni nel Basket

1 Abstract

Il presente lavoro propone un sistema per l'analisi automatica di video completi di partite di basket, con l'obiettivo di riconoscere e classificare le principali azioni di gioco. A supporto dello studio è stato costruito un dataset specifico, ottenuto da riprese di partite amatoriali acquisite mediante attrezzatura non professionale e successivamente segmentate e annotate manualmente.

Il problema affrontato riguarda l'individuazione di eventi caratterizzati da durate molto differenti, come passaggi, tiri e fasi di non gioco, e la successiva produzione di un report temporale degli eventi rilevati. La metodologia proposta combina un modello di object detection basato su RF-DETR, impiegato per individuare elementi rilevanti della scena, quali palla e canestro, con un modello di classificazione video basato su MoViNet, utilizzato per estrarre informazioni visive e temporali dai frame. Le informazioni prodotte dai due modelli vengono combinate per ottenere una rappresentazione più completa dell'azione e utilizzate per la classificazione finale.

Per l'elaborazione dei video completi è stata adottata una strategia a sliding window con finestre temporali sovrapposte di diversa durata: finestre brevi per aumentare la capacità di rilevazione dei passaggi e finestre più lunghe per riconoscere i tiri e determinarne il relativo esito. Le predizioni ottenute sulle singole finestre vengono successivamente aggregate mediante una fase di post-processing, che unisce gli eventi temporalmente correlati e risolve eventuali conflitti tra le classi.

I risultati ottenuti mostrano la fattibilità dell'approccio per la generazione automatica di un report degli eventi di partita, pur evidenziando alcune criticità legate al riconoscimento dei passaggi e alla corretta classificazione dell'esito dei tiri in condizioni di ripresa non controllate.

2 Introduzione

L'analisi automatica dei video sportivi rappresenta una delle sfide più rilevanti nell'ambito della Computer Vision, poiché mira a trasformare registrazioni video di durata variabile in informazioni strutturate e interpretabili. Nel caso del basket, tale compito risulta particolarmente complesso a causa della rapidità delle azioni, della possibile bassa risoluzione delle immagini e della frequente uscita parziale dall'inquadratura di giocatori, palla o canestro. Inoltre, le azioni di gioco presentano durate molto diverse tra loro: eventi brevi, come i passaggi, possono durare meno di un secondo, mentre azioni più articolate, come i tiri, richiedono un contesto temporale più ampio per riconoscere correttamente anche l'esito.

Un'ulteriore difficoltà riguarda la natura dei dati disponibili. Molti dataset pubblicamente accessibili relativi al basket sono costruiti su partite professionistiche, caratterizzate da qualità video elevata, inquadrature televisive stabili e condizioni di ripresa controllate. Al contrario, l'obiettivo di questo lavoro è affrontare uno scenario più realistico e meno controllato, basato su video amatoriali acquisiti tramite una videocamera non professionale montata su un supporto in

grado di seguire la palla durante il gioco. Questa impostazione rende il problema più complesso, ma anche più vicino a un possibile utilizzo pratico in contesti non professionistici.

Il presente progetto propone quindi una pipeline per il riconoscimento automatico delle principali azioni di una partita di basket, con l'obiettivo di produrre un report contenente i timestamp degli eventi rilevati. Il sistema considera azioni come passaggi, tiri da due, tiri da tre, tiri liberi, fasi di idle e non-gioco; per i tiri viene inoltre stimato l'esito dell'azione, distinguendo tra tiro segnato e tiro sbagliato.

La soluzione proposta combina informazioni visive estratte dai frame video con informazioni geometriche relative alla posizione e al movimento di palla e canestro. Le feature visive vengono ottenute tramite un backbone video basato su MoViNet, mentre le feature geometriche, derivate dalle rilevazioni di RF-DETR, vengono elaborate temporalmente mediante una GRU. Le due rappresentazioni vengono successivamente combinate e utilizzate da due classificatori finali: uno per il riconoscimento dell'azione e uno per la predizione dell'esito dei tiri.

Per applicare il modello a video completi, viene adottata una strategia a sliding window multi-scala, con finestre brevi per aumentare la probabilità di rilevare i passaggi e finestre più lunghe per fornire maggiore contesto ai tiri. Le predizioni ottenute sulle singole clip vengono infine aggregate tramite una fase di post-processing, con lo scopo di unire eventi temporalmente vicini, ridurre duplicazioni dovute all'overlap e generare un report finale degli eventi rilevati.

3 Stato dell'arte

Nel corso degli anni sono stati proposti diversi approcci per il video action recognition. I primi metodi basati su reti neurali profonde hanno cercato di modellare la dimensione temporale dei video tramite il campionamento di più frame o segmenti temporali. In questa direzione, le Temporal Segment Networks hanno introdotto un approccio basato sulla suddivisione del video in segmenti, con l'obiettivo di catturare informazioni distribuite lungo l'intera sequenza.

Accanto a questi modelli, una linea di ricerca rilevante riguarda lo sviluppo di architetture efficienti per il riconoscimento video. In questo contesto si collocano i MoViNet, progettati per ridurre il costo computazionale e la memoria richiesta rispetto alle classiche reti convoluzionali 3D, mantenendo buone capacità di riconoscimento temporale. Tali caratteristiche risultano particolarmente utili quando si vuole applicare un modello a video completi o a sistemi potenzialmente vicini all'elaborazione in tempo reale.

Nel caso degli sport di squadra, e in particolare del basket, il solo contenuto visivo dei frame può non essere sufficiente per distinguere correttamente alcune azioni. Elementi come la posizione della palla, la posizione del canestro, la distanza tra palla e canestro e l'evoluzione temporale del movimento possono fornire informazioni aggiuntive fondamentali. Per questo motivo, molti sistemi di analisi sportiva integrano moduli di object detection o tracking, finalizzati all'individuazione di oggetti e soggetti rilevanti nella scena. In un contesto come quello del basket, tali tecniche possono essere utilizzate per individuare elementi chiave come palla e canestro e derivare da essi feature geometriche utili alla classificazione dell'azione.

Un ulteriore aspetto centrale riguarda la modellazione temporale. Poiché molte azioni non sono riconoscibili da un singolo frame, è necessario considerare l'evoluzione delle informazioni nel tempo. Le reti ricorrenti, come le GRU, sono state introdotte per codificare sequenze di dati e produrre rappresentazioni compatte che tengano conto della dinamica temporale. Nel caso di feature geometriche frame-by-frame, una GRU può essere utilizzata per riassumere il comportamento temporale della palla e del canestro, ad esempio distinguendo traiettorie compatibili con un passaggio da traiettorie più coerenti con un tiro.

Per quanto riguarda il basket, esistono dataset e lavori dedicati al riconoscimento di azioni, alla

stima di abilità, al tracking dei giocatori e all'analisi di eventi. Tuttavia, molte soluzioni sono pensate per dati di qualità elevata, contesti professionistici, riprese controllate o task specifici. Rimane quindi aperta la necessità di sviluppare pipeline robuste anche su video amatoriali, caratterizzati da risoluzione variabile, inquadrature non stabili, occlusioni e movimenti rapidi della palla. Inoltre, un ulteriore problema riguarda la diversa durata delle azioni: i passaggi possono essere estremamente brevi, mentre i tiri richiedono un contesto temporale più ampio per determinare correttamente anche l'esito.

Il presente lavoro si inserisce in questo contesto proponendo una pipeline per l'analisi automatica di video completi di partite di basket amatoriali, acquisiti mediante attrezzatura non professionale. A supporto dello studio, è stato inoltre realizzato un dataset specifico, costruito a partire dalle registrazioni raccolte e annotato per il riconoscimento delle principali azioni di gioco.

4 Metodologia proposta

La metodologia proposta si basa su una pipeline progettata per riconoscere automaticamente le principali azioni presenti in una partita di basket a partire da clip video. L'obiettivo è quindi costruire un modello in grado di classificare l'azione verificata in una clip e applicarlo a intere partite di basket con lo scopo di produrre un report temporale degli eventi rilevati. Il sistema è composto da due modelli: uno di object detection che estrae informazioni geometriche e uno visivo che utilizza le feature prodotte dal modello precedente e in più estrae feature visive dalle immagini e utilizza il tutto per effettuare le predizioni. Suddividiamo questo capitolo in due parti: nella sezione 4.1 descriviamo i dataset utilizzati e in che modo sono stati costruiti i modelli, nella sezione 4.2 descriviamo come è stata costruita la pipeline per l'applicazione del modello su video di lunga durata.

4.1 Costruzione del modello

4.1.1 Dataset

Il dataset utilizzato in questo lavoro è stato costruito a partire da 6 video di partite di basket acquisite in un contesto non professionale. Le riprese sono state effettuate mediante una videocamera non professionale a 30 fps montata su un supporto in grado di seguire il movimento della palla durante il gioco. Questa scelta ha permesso di lavorare su dati più vicini a uno scenario reale e amatoriale, caratterizzato da condizioni meno controllate rispetto alle riprese professionistiche o televisive.

Le registrazioni presentano diverse criticità tipiche dei video amatoriali: variazioni di inquadratura, possibile sfocatura dovuta al movimento, occlusioni parziali dei giocatori, uscita temporanea della palla o del canestro dall'inquadratura e cambiamenti rapidi nella scena. Tali caratteristiche rendono il problema del riconoscimento automatico delle azioni più complesso, ma allo stesso tempo più rappresentativo di un possibile utilizzo pratico in contesti non professionistici. In più il dataset risulta essere fortemente sbilanciato, il che implica la necessità di applicare tecniche di bilanciamento per evitare problemi di overfitting.

A partire dai video completi sono state estratte manualmente clip contenenti singole azioni o specifiche fasi di gioco. Ogni clip è stata annotata assegnando un'etichetta corrispondente all'azione principale presente nella sequenza. Le classi considerate per la classificazione sono: passaggio, tiroDaDue0, tiroDaDue1, tiroDaTre0, tiroDaTre1, tiroLibero0, tiroLibero1, idle e non-gioco. Per quanto riguarda le azioni di tiro, il suffisso 0 sta per tiro sbagliato mentre il suffisso 1 sta per tiro segnato, la classe idle indica azioni non rilevanti mentre la classe non gioco indica eventi che avvengono a gioco interrotto.

La suddivisione manuale in clip ha permesso di costruire un dataset supervisionato per l'addestramento del modello. Tuttavia, le clip ottenute presentano durate variabili, poiché le diverse azioni del basket non occupano lo stesso intervallo temporale. In particolare, i passaggi sono generalmente azioni molto brevi, spesso inferiori al secondo, mentre i tiri richiedono un contesto temporale più ampio per includere la preparazione, il rilascio della palla e l'eventuale esito. Questa variabilità rappresenta una delle principali difficoltà del progetto, poiché una finestra temporale unica può risultare troppo lunga per i passaggi e troppo corta per alcuni tiri.

Una possibile sintesi della distribuzione del dataset è riportata nella Tabella 1.

Classe	Numero di clip	Durata media(s)
passaggio	2505	0.5
tiroDaDue0	266	1.28
tiroDaDue1	189	1.33
tiroDaTre0	152	1.87
tiroDaTre1	58	1.75
tiroLibero0	82	1.87
tiroLibero1	111	1.7
idle	854	0.71
non-gioco	1503	2.24

Tabella 1: Distribuzione del dataset delle azioni.

Ogni clip dei video è stata suddivisa tra training, validation e test set in modo tale che le clip appartenenti allo stesso video si trovano nello stesso set e di prevenire il data leakage. Il training set è composto dalle clip estratte da 4 dei 6 video totali ed è stato utilizzato per l'addestramento del modello, il validation set è composto dalle clip estratte da un video ed è stato utilizzato per il monitoraggio delle prestazioni durante l'addestramento e la selezione del miglior checkpoint, mentre il test set è composto dalle clip estratte da un video ed è stato utilizzato per la valutazione finale su dati non visti.

4.1.2 Dataset per il rilevamento di palla e canestro

Oltre al dataset destinato alla classificazione delle azioni, è stato costruito un secondo dataset per l'addestramento del modulo di object detection. Questo dataset è stato realizzato estraendo frame da diverse clip del training set del dataset principale e annotando manualmente le bounding box di due elementi fondamentali della scena: la palla e il canestro.

La scelta di annotare questi due oggetti deriva dal ruolo centrale che essi ricoprono nella comprensione delle azioni di basket. La posizione della palla, la sua distanza dal canestro e la sua evoluzione temporale sono infatti informazioni rilevanti per distinguere azioni come passaggi e tiri. Il canestro, inoltre, fornisce un riferimento spaziale utile per interpretare la traiettoria della palla e per stimare l'esito di un tiro.

Per ogni frame selezionato sono state quindi annotate manualmente le istanze visibili delle classi palla e canestro. Quando uno degli oggetti non era visibile o risultava completamente fuori inquadratura, non veniva associata alcuna bounding box. Il dataset così ottenuto è stato utilizzato per addestrare un modello RF-DETR con due classi di rilevamento: palla e canestro.

Una possibile sintesi del dataset di detection è riportata nella Tabella 3.

Per quanto riguarda le performance ottenute, sono riportate le metriche nella Tabella 2

Classe	AP@50:95	AR	F1-score	Precision	Recall
Palla	0,5004	0,5611	0,9247	0,9567	0,8947
Canestro	0,6079	0,6884	0,9862	0,9817	0,9907

Tabella 2: Prestazioni di RF-DETR per ciascuna classe sul validation set.

Classe	Numero di annotazioni	Note
palla	1252	Oggetto piccolo, spesso in movimento rapido e talvolta parzialmente occluso
canestro	1176	Oggetto più stabile, ma non sempre presente nell'inquadratura
Totale frame annotati	1321	Frame estratti da diverse clip del dataset principale

Tabella 3: Composizione del dataset per il rilevamento di palla e canestro.

4.1.3 Preprocessing delle clip

Ogni clip del dataset è stata sottoposta a una fase di preprocessing. Da ciascuna clip sono stati estratti 32 frame distribuiti uniformemente lungo la sua durata. Questa scelta consente di rappresentare ogni azione con un numero fisso di frame, indipendentemente dalla durata originale della clip. Le clip aventi un numero di frame inferiore a 32 sono state riempite con frame nulli, quindi per aiutare il modello a riconoscere frame reali da frame nulli, per ogni clip è stata costruita una maschera che è un vettore di 32 valori in cui ogni valore indica se il frame nella posizione i -esima è reale o nullo. Infine i frame sono stati ridimensionati a una risoluzione di 896×896 e salvati in una cache, in modo da velocizzare le successive fasi di addestramento.

4.1.4 Addestramento del modello di object detection

La prima componente della pipeline è costituita da un modulo di object detection basato su RF-DETR Large, utilizzato per rilevare palla e canestro nei frame della clip.

Il modello RF-DETR è stato addestrato utilizzando il dataset di frame annotati manualmente. L'obiettivo di questo modulo non è classificare direttamente le azioni di gioco, ma individuare automaticamente palla e canestro all'interno dei frame. Per ogni immagine, il detector produce le bounding box degli oggetti rilevati, le rispettive classi e un valore di confidenza associato alla predizione. Sul dataset è stato applicato un augmentation, più precisamente un flip orizzontale con una variazione della luminosità compresa tra -15% e +15%, in modo tale da avere a disposizione più frame per l'addestramento del modello.

Una volta addestrato, RF-DETR è stato utilizzato come componente preliminare della pipeline principale. Per ciascun frame campionato da una clip, il detector viene applicato per ricavare la posizione della palla e del canestro.

In particolare, a partire dalle bounding box rilevate vengono calcolate feature relative alla presenza dell'oggetto, alla posizione normalizzata del centro della bounding box, alla dimensione della bounding box e alla confidenza della rilevazione. Inoltre, quando sia palla sia canestro sono presenti, vengono calcolate feature relazionali come la distanza tra i due oggetti e le differenze tra le rispettive coordinate. Infine, viene stimata la variazione della posizione della palla tra frame consecutivi, così da fornire al modello informazioni sul movimento della palla nel tempo.

Il modello produce quindi un vettore di 19 dimensioni per ogni clip, che successivamente viene trasformato tramite un encoder lineare in una rappresentazione di dimensione maggiore composto da 128 valori. Questo passaggio consente al modello di apprendere combinazioni più informative delle feature geometriche grezze. La sequenza di feature geometriche codificate viene poi passata a una GRU bidirezionale. La GRU ha il compito di modellare l'evoluzione temporale delle informazioni geometriche, riassumendo il comportamento della palla e del canestro lungo tutta la

clip. Questo è importante perché una singola posizione della palla non è sufficiente per distinguere correttamente un'azione: ciò che conta è anche il modo in cui la palla si muove nel tempo. Questo vettore sarà uno dei due elementi di input per il classificatore finale.

4.1.5 Estrazione delle feature visive con MoViNet

La componente visiva della pipeline utilizza MoViNet come backbone video. Il classificatore originale di MoViNet viene rimosso e sostituito con un modulo identità, in modo che la rete non produca direttamente una classe finale, ma venga utilizzata come estrattore di feature visive. In questo modo, MoViNet elabora i frame della clip e restituisce una rappresentazione compatta del contenuto spazio-temporale del video, composta da 640 valori per clip.

Le feature estratte da MoViNet rappresentano informazioni legate al movimento dei giocatori, alla postura, alla dinamica generale della scena e all'evoluzione visiva dell'azione. Tali informazioni sono particolarmente utili per distinguere azioni che dipendono dal gesto atletico, come un tiro, un passaggio o una fase di gioco inattiva.

4.1.6 Fusione delle rappresentazioni

Una volta ottenute le feature visive da MoViNet e le feature geometriche temporali dalla GRU, le due rappresentazioni vengono concatenate in un unico vettore di fusione. Questo vettore rappresenta congiuntamente sia il contenuto visivo della clip sia la dinamica geometrica di palla e canestro.

La rappresentazione fusa viene normalizzata tramite un layer di normalizzazione e successivamente inviata a due classificatori finali. Il primo classificatore, denominato `head_action`, si occupa del riconoscimento dell'azione principale della clip. Il secondo classificatore, denominato `head_outcome`, si occupa invece della predizione dell'esito dei tiri, distinguendo tra tiro segnato e tiro sbagliato.

Questa architettura multi-task permette quindi di affrontare due problemi collegati ma distinti: da un lato la classificazione dell'azione, dall'altro la classificazione dell'esito nel caso in cui l'azione rilevata sia un tiro.

4.1.7 Addestramento del modello finale

Il modello è stato addestrato utilizzando il dataset suddiviso in training set, validation set e test set. Il training set è stato impiegato per l'ottimizzazione dei parametri, il validation set per monitorare l'andamento dell'addestramento e selezionare il checkpoint migliore, mentre il test set è stato utilizzato esclusivamente al termine del training per la valutazione finale su dati non osservati.

Per ogni clip vengono forniti al modello i 32 frame campionati uniformemente, la sequenza delle feature geometriche estratte mediante RF-DETR, la maschera dei frame validi, l'etichetta dell'azione e, per le clip contenenti un tiro, l'etichetta relativa all'esito. L'addestramento viene effettuato con batch di 8 clip per un massimo di 30 epoche.

Il backbone MoViNet A2 viene inizializzato con pesi pre-addestrati. La maggior parte dei suoi parametri viene mantenuta congelata, mentre soltanto l'ultimo blocco viene lasciato addestrabile. Questa scelta consente di sfruttare le rappresentazioni visive già apprese dal modello, limitando allo stesso tempo il numero di parametri da ottimizzare e riducendo il rischio di overfitting. Vengono invece addestrati completamente l'encoder delle feature geometriche, la GRU bidirezionale, il livello di fusione e le due teste di classificazione.

La funzione di perdita complessiva è composta da due termini:

$$\mathcal{L} = \mathcal{L}_{\text{azione}} + \lambda_{\text{outcome}} \mathcal{L}_{\text{outcome}}, \quad (1)$$

dove $\mathcal{L}_{\text{azione}}$ è la Cross Entropy Loss relativa alla classificazione dell'azione e viene calcolata su tutte le clip, mentre $\mathcal{L}_{\text{outcome}}$ è la Cross Entropy Loss relativa all'esito del tiro e viene calcolata soltanto sui campioni appartenenti alle classi di tiro. Il coefficiente λ_{outcome} è impostato a 1. In assenza di clip di tiro all'interno di un batch, la loss complessiva coincide quindi con la sola loss dell'azione.

Per mitigare lo sbilanciamento del dataset vengono utilizzati pesi di classe nella Cross Entropy Loss. Per ogni classe c , il peso è calcolato come:

$$w_c = \frac{1}{\sqrt{n_c}}, \quad (2)$$

dove n_c rappresenta il numero di esempi della classe nel training set. I pesi vengono successivamente normalizzati rispetto alla loro media, in modo da mantenere una scala complessiva stabile. Tale procedura viene applicata separatamente sia alle classi delle azioni sia alle due classi relative all'esito, segnato e non-segnato. In questo modo, gli errori commessi sulle classi meno rappresentate contribuiscono maggiormente alla funzione di perdita.

L'ottimizzazione viene effettuata mediante AdamW, con learning rate iniziale pari a 10^{-4} e weight decay pari a 10^{-4} . Il weight decay introduce una regolarizzazione sui parametri e contribuisce a limitare l'overfitting. È inoltre utilizzato uno scheduler di tipo ReduceLROnPlateau, che dimezza il learning rate quando le prestazioni sul validation set non migliorano per tre epoche consecutive, fino a un valore minimo pari a 10^{-6} .

Dopo ogni epoca vengono calcolate sul validation set l'accuracy e il macro recall per la classificazione delle azioni, oltre all'accuracy e alla balanced accuracy per la classificazione dell'esito. Il criterio utilizzato per selezionare il modello migliore è definito come:

$$\text{Score}_{\text{val}} = 0,5 \text{MacroRecall}_{\text{azione}} + 0,5 \text{BalancedAccuracy}_{\text{outcome}}. \quad (3)$$

Questo criterio attribuisce la stessa importanza ai due compiti e consente di evitare che la selezione del checkpoint dipenda esclusivamente dall'accuracy complessiva, che potrebbe essere influenzata dalle classi maggioritarie.

Il checkpoint viene salvato ogni volta che il valore dello score di validazione migliora. Nel file vengono memorizzati i pesi del modello, lo stato dell'ottimizzatore, lo stato dello scheduler, le mappature delle classi e i pesi utilizzati nelle funzioni di perdita. L'addestramento viene interrotto anticipatamente se non si osservano miglioramenti per otto epoche consecutive. Al termine, il checkpoint migliore viene ricaricato e valutato sul test set.

4.2 Costruzione della pipeline

4.2.1 Analisi multi-scala e generazione degli eventi

La pipeline sviluppata analizza automaticamente il video completo di una partita di basket e individua le principali azioni di gioco, associando a ciascun evento un intervallo temporale, una classe, una confidenza e, nel caso dei tiri, il relativo esito.

Poiché le clip del dataset presentano durate differenti, durante l'inferenza vengono utilizzate due finestre temporali parallele:

- una finestra SHORT di 0,8 secondi, dedicata principalmente ai passaggi;

- una finestra LONG di 2,0 secondi, utilizzata per riconoscere i tiri e osservarne la traiettoria e l'esito.

Le due finestre terminano nello stesso istante e una nuova coppia di predizioni viene prodotta ogni 0,4 secondi. La sovrapposizione tra finestre consecutive permette di rilevare azioni che iniziano in istanti differenti.

Le due scale vengono specializzate escludendo alcune classi. La finestra SHORT non può restituire classi di tiro, mentre dalla finestra LONG viene esclusa la classe passaggio. Se la classe più probabile appartiene a quelle escluse, viene selezionata la classe con probabilità maggiore tra quelle consentite. In questo modo, le azioni brevi vengono valutate mediante la finestra corta, mentre i tiri vengono riconosciuti utilizzando una quantità maggiore di contesto temporale.

Filtro passaggio-palleggio Quando la finestra SHORT predice un passaggio, viene calcolata la velocità media della palla considerando solamente i frame nei quali essa è stata rilevata consecutivamente. Se la velocità media è inferiore alla soglia 0,010, la predizione viene trasformata in idle.

Questo filtro ha lo scopo di ridurre i falsi passaggi dovuti a movimenti locali della palla, come il palleggio, che generalmente produce uno spostamento inferiore rispetto a un passaggio reale.

Fusione delle predizioni Le predizioni SHORT e LONG vengono combinate mediante un meccanismo di isteresi. Inizialmente è attiva la finestra SHORT. Il sistema passa alla finestra LONG quando quest'ultima rileva un tiro con confidenza almeno pari a 0,80.

Una volta attivata, la finestra LONG rimane selezionata finché continua a riconoscere un tiro con confidenza almeno pari a 0,65. L'uso di due soglie differenti riduce le oscillazioni tra passaggio e tiro causate da piccole variazioni di confidenza tra finestre consecutive. Per ogni coppia di finestre viene salvata una riga nel report grezzo, che conserva tutte le predizioni prodotte durante lo scorrimento del video e permette di analizzare nel dettaglio il comportamento del modello.

Soppressione dei conflitti tra passaggi e tiri Prima della costruzione degli eventi finali vengono individuati gli intervalli nei quali la finestra LONG ha rilevato un tiro con confidenza almeno pari a 0,75.

Se un passaggio rilevato dalla finestra SHORT si sovrappone temporalmente a uno di questi intervalli, viene trasformato in no_action. Questa regola evita che lo stesso movimento venga inserito nel report finale sia come passaggio sia come tiro.

La modifica viene applicata solamente alle predizioni utilizzate per la generazione degli eventi, mentre il report grezzo mantiene le predizioni originali.

Raggruppamento in eventi Poiché una nuova predizione viene prodotta ogni 0,4 secondi, più finestre consecutive possono riferirsi alla stessa azione reale. Le predizioni con confidenza inferiore a 0,75 vengono innanzitutto convertite in no_action; successivamente, le finestre consecutive con la stessa classe vengono raggruppate in un unico evento.

Per ogni gruppo vengono memorizzati il tempo iniziale, il tempo finale e l'insieme delle finestre che lo compongono. Gli eventi di tiro temporalmente sovrapposti vengono inoltre uniti anche quando appartengono a sottoclassi differenti, così da ridurre le duplicazioni dovute a oscillazioni tra tiro da due, tiro da tre e tiro libero.

L'azione finale viene determinata mediante un voto pesato: per ciascuna classe vengono sommate le confidenze delle finestre appartenenti al gruppo e viene selezionata la classe con il valore complessivo più elevato.

Classificazione dell'esito L'esito viene valutato solamente quando l'azione finale è un tiro. Le predizioni relative all'esito vengono confrontate considerando confidenza e posizione temporale.

Il margine di pareggio è impostato a 1,0; di conseguenza, tra predizioni differenti viene generalmente privilegiata la finestra temporalmente più recente, che ha maggiori probabilità di contenere la conclusione della traiettoria della palla.

Report finale degli eventi Il report finale contiene solamente gli eventi rilevanti, escludendo le classi idle, non-gioco e no_action.

Per ogni evento vengono salvati:

- indice progressivo;
- azione riconosciuta;
- tempo e timestamp iniziali e finali;
- durata;
- confidenza dell'azione;
- esito e relativa confidenza;
- numero di finestre raggruppate.

Il report degli eventi costituisce quindi una rappresentazione compatta e temporalmente aggregata delle predizioni prodotte sul video completo.

5 Esperimenti e risultati

5.1 Esperimenti preliminari e selezione dell'architettura

Prima di definire l'architettura finale sono state sperimentate diverse configurazioni del modello, con l'obiettivo di individuare la soluzione più adatta alla classificazione delle azioni di basket presenti nel dataset. Tali esperimenti hanno permesso di valutare il contributo delle differenti componenti e di identificare i principali limiti degli approcci iniziali.

Le prime configurazioni erano basate sulla combinazione di una rete convoluzionale e di una rete ricorrente. Come backbone visivi sono state sperimentate MobileNetV2, MobileNetV3, MobileNetV3 Large ed EfficientNetB0, mentre per la modellazione temporale sono state utilizzate sia una GRU unidirezionale sia una GRU bidirezionale. L'obiettivo era ottenere un modello leggero, caratterizzato da un costo computazionale contenuto e da tempi di inferenza compatibili con un'elaborazione prossima al tempo reale. Tali configurazioni hanno tuttavia ottenuto prestazioni inferiori rispetto al modello finale, soprattutto nel riconoscimento delle diverse tipologie di tiro e nella classificazione del relativo esito. Una possibile causa è riconducibile alla quantità insufficiente di informazioni specifiche sulla palla contenute nelle rappresentazioni visive prodotte dalle reti convoluzionali. La palla costituisce infatti un oggetto di dimensioni molto ridotte, spesso sfocato a causa del movimento. Durante l'estrazione e l'aggregazione delle feature, le informazioni relative a tale oggetto possono quindi essere diluite all'interno della rappresentazione globale della scena.

Successivamente è stata sperimentata un'ulteriore architettura basata sulla combinazione di un backbone visivo DINO e di una GRU per la modellazione temporale. Questa configurazione ha mostrato un miglioramento rispetto agli approcci precedenti, grazie alla maggiore qualità delle rappresentazioni visive estratte. Nonostante ciò, il modello continuava a presentare difficoltà nella classificazione dell'esito dei tiri, poiché la sola informazione visiva non risultava sempre sufficiente a descrivere con precisione la traiettoria della palla e la sua relazione con il canestro

Sulla base dei risultati preliminari è stata quindi scelta l'architettura descritta nella Sezione ???. La combinazione tra le feature visive estratte mediante MoViNet e le feature geometriche elaborate dalla GRU ha prodotto risultati più stabili, consentendo di raggiungere prestazioni superiori sia nella classificazione delle azioni sia nella predizione dell'esito.

Parallelamente alla sperimentazione delle diverse architetture, sono state valutate varie strategie per ridurre gli effetti dello sbilanciamento del dataset, che durante i primi addestramenti determinava frequentemente fenomeni di overfitting. In una prima fase è stata applicata una tecnica di data augmentation selettiva alle classi meno rappresentate, generando nuove versioni delle clip mediante flip orizzontale e riduzione della luminosità. L'obiettivo era aumentare artificialmente la variabilità delle classi minoritarie e ridurre la tendenza del modello a privilegiare quelle maggiormente presenti nel training set.

Nonostante l'incremento del numero di campioni, il fenomeno di overfitting continuava a manifestarsi. Le trasformazioni applicate modificavano infatti principalmente l'aspetto delle immagini, ma non introducevano una reale variabilità nelle azioni, nelle traiettorie della palla, nelle inquadrature o nelle situazioni di gioco. Le clip aumentate rimanevano quindi fortemente correlate con gli esempi originali e non fornivano al modello informazioni sufficientemente differenti da migliorare in modo significativo la generalizzazione.

Per questo motivo, nella configurazione finale si è scelto di gestire lo sbilanciamento direttamente durante l'ottimizzazione, utilizzando una Cross Entropy Loss pesata. Alle classi meno rappresentate è stato assegnato un peso maggiore, calcolato in funzione della loro frequenza nel training set, così da aumentare il contributo dei relativi errori senza duplicare ulteriormente i campioni disponibili.

5.2 Configurazione sperimentale

Il modello è stato valutato sulle clip appartenenti al validation set e al test set. Il validation set è stato utilizzato durante l'addestramento per monitorare le prestazioni e selezionare il checkpoint migliore, mentre il test set è stato mantenuto separato e impiegato esclusivamente per la valutazione finale.

La classificazione delle azioni comprende cinque classi:

- non-gioco;
- passaggio;
- tiroDaDue;
- tiroDaTre;
- tiroLibero.

In cui non.gioco rappresenta l'unione delle classi idle e non-gioco.

Per le clip appartenenti alle classi di tiro è stato inoltre valutato un secondo compito, relativo alla classificazione dell'esito tra segnato e non-segnato.

Le prestazioni sono state misurate attraverso accuracy, precision, recall, macro recall e F1-score. Il macro recall è particolarmente significativo in questo contesto, poiché il numero di campioni non è uniforme tra le classi e tale metrica assegna la stessa importanza a ciascuna categoria.

Nelle confusion matrix, le righe rappresentano le classi reali e le colonne quelle predette. Gli elementi sulla diagonale principale corrispondono alle classificazioni corrette, mentre gli elementi esterni alla diagonale rappresentano gli errori.

5.3 Risultati sul validation set

Il checkpoint migliore è stato selezionato all'epoca 29, in corrispondenza di una validation loss pari a 0,6986. Sul validation set il modello ha ottenuto:

- accuracy delle azioni: 0,8722;
- macro precision delle azioni: 0,8091;
- macro recall delle azioni: 0,8373;
- macro F1-score delle azioni: 0,8086;
- accuracy dell'esito: 0,8923;
- balanced accuracy dell'esito: 0,8900.

La confusion matrix relativa alla classificazione delle azioni è la seguente.

Classe reale \ Classe predetta	non-gioco	passaggio	tiroDaDue	tiroDaTre	tiroLibero
non-gioco	226	35	0	1	1
passaggio	16	196	0	0	0
tiroDaDue	2	0	20	6	4
tiroDaTre	0	0	0	15	0
tiroLibero	0	0	2	2	14

Tabella 4: Confusion matrix delle azioni sul validation set.

Il validation set comprende complessivamente 540 clip. Il recall ottenuto per ciascuna classe è riportato nella tabella seguente.

Classe	Precision	Recall	F1-score	Numero di clip
non-gioco	0,9262	0,8593	0,8915	263
passaggio	0,8485	0,9245	0,8849	212
tiroDaDue	0,9091	0,6250	0,7407	32
tiroDaTre	0,6250	1,0000	0,7692	15
tiroLibero	0,7368	0,7778	0,7568	18

Tabella 5: Metriche per classe sul validation set.

La classe riconosciuta con il recall più elevato è tiroDaTre, per la quale tutte le 15 clip presenti nel validation set sono state classificate correttamente. Tale risultato deve tuttavia essere interpretato considerando il numero ridotto di campioni e la precision pari a 0,6250. Infatti, alcune clip appartenenti ad altre tipologie di tiro sono state erroneamente assegnate alla classe tiroDaTre.

Anche la classe passaggio presenta risultati elevati, con 196 classificazioni corrette su 212 clip e un recall pari a 0,9245. I principali errori riguardano 16 passaggi classificati come non-gioco.

La classe maggiormente problematica è tiroDaDue, che presenta un recall pari a 0,6250. Delle 32 clip disponibili, 20 sono state riconosciute correttamente, mentre 6 sono state classificate come

tiroDaTre e 4 come tiroLibero. Questo risultato evidenzia una difficoltà nella distinzione tra le diverse sottoclassi di tiro.

Un'ulteriore confusione significativa riguarda non-gioco e passaggio: 35 clip di non-gioco sono state classificate come passaggi. La causa può essere ricondotta alla breve durata delle clip di passaggio in cui il modello potrebbe aver facilmente confuso un semplice palleggio con un passaggio.

Classificazione dell'esito sul validation set La confusion matrix relativa all'esito del tiro è la seguente.

Esito reale \ Esito predetto	non-segnato	segnato
non-segnato	36	4
segnato	3	22

Tabella 6: Confusion matrix dell'esito sul validation set.

La valutazione dell'esito è stata effettuata su 65 clip di tiro. Il modello ha riconosciuto correttamente 36 dei 40 tiri non segnati e 22 dei 25 tiri segnati.

Esito	Precision	Recall	F1-score
non-segnato	0,9231	0,9000	0,9114
segnato	0,8462	0,8800	0,8627

Tabella 7: Metriche di classificazione dell'esito sul validation set.

Il macro F1-score relativo all'esito è pari a 0,8871, indicando prestazioni complessivamente bilanciate tra le due classi.

5.4 Risultati sul test set

Il checkpoint selezionato sul validation set è stato successivamente valutato sulle clip del test set. Sono stati ottenuti i seguenti risultati:

- test loss: 1,1644;
- accuracy delle azioni: 0,8477;
- macro precision delle azioni: 0,8046;
- macro recall delle azioni: 0,8248;
- macro F1-score delle azioni: 0,8113;
- accuracy dell'esito: 0,8562;
- balanced accuracy dell'esito: 0,8500.

La confusion matrix delle azioni sul test set è riportata di seguito.

Il test set comprende complessivamente 939 clip. I risultati per classe sono riportati nella tabella seguente.

La classe passaggio presenta il valore di precision più elevato, pari a 0,9213, e 433 classificazioni corrette su 506 clip. Il recall è tuttavia inferiore rispetto a quello registrato sul validation set, principalmente a causa di 63 passaggi classificati come non-gioco.

Classe reale \ Classe predetta	non-gioco	passaggio	tiroDaDue	tiroDaTre	tiroLibero
non-gioco	232	34	2	5	0
passaggio	63	433	8	1	1
tiroDaDue	2	3	81	10	2
tiroDaTre	2	0	4	32	0
tiroLibero	0	0	6	0	18

Tabella 8: Confusion matrix delle azioni sul test set.

Classe	Precision	Recall	F1-score	Numero di clip
non-gioco	0,7759	0,8498	0,8112	273
passaggio	0,9213	0,8557	0,8873	506
tiroDaDue	0,8020	0,8265	0,8141	98
tiroDaTre	0,6667	0,8421	0,7442	38
tiroLibero	0,8571	0,7500	0,8000	24

Tabella 9: Metriche per classe sul test set.

La classe non-gioco presenta un recall pari a 0,8498. Tra i 273 campioni reali, 232 vengono riconosciuti correttamente e 34 vengono classificati come passaggi. Le confusioni tra non-gioco e passaggio rappresentano quindi la principale fonte di errore in termini assoluti.

Le prestazioni relative a tiroDaDue migliorano rispetto al validation set, raggiungendo un recall pari a 0,8265. Rimane tuttavia una confusione con tiroDaTre: 10 clip di tiro da due vengono assegnate alla classe tiro da tre.

La classe tiroDaTre raggiunge un recall pari a 0,8421, ma una precision di 0,6667. Ciò significa che la maggior parte dei veri tiri da tre viene riconosciuta, ma il modello assegna a questa classe anche alcuni campioni appartenenti ad altre tipologie di tiro.

Il tiroLibero presenta il recall più basso, pari a 0,7500. Delle 24 clip reali, 18 vengono classificate correttamente e 6 vengono confuse con il tiro da due.

Classificazione dell'esito sul test set La confusion matrix relativa all'esito sul test set è la seguente.

Esito reale \ Esito predetto	non-segnato	segnato
non-segnato	81	9
segnato	14	56

Tabella 10: Confusion matrix dell'esito sul test set.

L'esito è stato valutato su 160 clip di tiro. Il modello riconosce correttamente 81 tiri non segnati su 90 e 56 tiri segnati su 70.

Il macro F1-score relativo all'esito è pari a 0,8527. Il modello mantiene un recall elevato per i tiri non segnati, pari a 0,9000, mentre incontra maggiori difficoltà con i tiri segnati, per i quali il recall scende a 0,8000.

5.5 Analisi degli errori

Le confusion matrix evidenziano due principali categorie di errore.

La prima riguarda la distinzione tra passaggio e non-gioco. Sul test set, 63 passaggi vengono classificati come non-gioco e 34 clip di non-gioco vengono classificate come passaggi. Queste due

Esito	Precision	Recall	F1-score
non-segnato	0,8526	0,9000	0,8757
segnato	0,8615	0,8000	0,8296

Tabella 11: Metriche di classificazione dell’esito sul test set.

classi rappresentano la maggior parte del dataset e possono condividere sequenze visive simili, soprattutto quando il passaggio occupa solamente una piccola parte della clip o quando nelle sequenze non-gioco sono comunque presenti movimenti della palla. Queste due classi vengono confuse soprattutto in fase di inferenza, a causa della breve durata delle azioni di passaggio che possono essere confuse con dei semplici palleggi e viceversa.

La seconda categoria riguarda la distinzione tra le sottoclassi di tiro. In particolare, il modello tende a confondere tiro da due e tiro da tre. Le due azioni presentano movimenti simili e si distinguono soprattutto per la posizione del giocatore rispetto alla linea dei tre punti, che può non essere chiaramente visibile nelle riprese.

Il tiro libero viene invece confuso principalmente con il tiro da due. Ciò può verificarsi quando l’inquadratura non mostra chiaramente la linea del tiro libero o la disposizione statica degli altri giocatori.

Per quanto riguarda l’esito, il modello riconosce più facilmente i tiri non segnati rispetto a quelli segnati. Alcuni tiri segnati vengono classificati come non segnati quando la palla è parzialmente occlusa, non viene rilevata in prossimità del canestro oppure la parte conclusiva della traiettoria non è sufficientemente visibile.

6 Conclusioni

Il sistema proposto ha raggiunto risultati complessivamente soddisfacenti nel riconoscimento automatico delle principali azioni di una partita di basket. Sul test set, il modello ha ottenuto un’accuracy pari a circa l’85%, dimostrando una buona capacità di generalizzazione su clip non utilizzate durante l’addestramento.

L’analisi delle confusion matrix ha tuttavia evidenziato alcuni limiti. Le principali difficoltà riguardano la distinzione tra le classi passaggio e non-gioco, oltre alla separazione tra le diverse tipologie di tiro. In particolare, il modello tende a confondere alcuni tiri da due con tiri da tre e alcuni tiri liberi con tiri da due. Tali errori possono essere ricondotti alla somiglianza visiva tra le azioni e alla difficoltà di individuare con precisione la posizione del giocatore rispetto alle linee del campo.

Durante l’applicazione del modello a video completi sono emerse ulteriori criticità. In alcuni casi, passaggi e tiri vengono confusi tra loro, soprattutto quando le rispettive finestre temporali si sovrappongono. Inoltre, alcune fasi di idle vengono erroneamente classificate come passaggi, ad esempio quando un giocatore palleggia senza effettuare un reale trasferimento della palla verso un compagno.

Una possibile causa di tali errori è rappresentata dalla struttura del dataset. Le clip relative ai passaggi hanno infatti una durata media molto breve e spesso contengono solamente il gesto principale, senza includere un contesto temporale sufficientemente ampio. Di conseguenza, il modello può avere difficoltà a distinguere un passaggio da altri movimenti rapidi della palla, come il palleggio o la fase iniziale di un tiro.

Nonostante questi limiti, il sistema ha raggiunto un buon risultato complessivo, soprattutto considerando la complessità dello scenario analizzato, caratterizzato da video amatoriali, inquadrature

variabili, occlusioni e movimenti rapidi della palla. La combinazione tra feature visive, informazioni geometriche e modellazione temporale si è dimostrata efficace per il riconoscimento delle azioni e per la classificazione dell'esito dei tiri.

Possibili sviluppi futuri comprendono l'ampliamento e il bilanciamento del dataset, l'inserimento di un maggior numero di azioni ambigue, l'estensione temporale delle clip di passaggio e il miglioramento della segmentazione degli eventi nei video completi. Tali interventi potrebbero ridurre ulteriormente le confusioni tra passaggi, tiri e fasi di inattività, aumentando la robustezza della pipeline in scenari reali.